

```
set.seed(42)
library(ggplot2)
```


Praktikum 7

Aufgabe 1

Zuerst berechnen wir die Punkte

```
h1 = function (X) {
  return(X)
}
h2 = function (X) {
  ind = as.numeric(X >= 1)
  return((X-1)^2 * ind)
}
Y = function (X) {
  y = 1 + h1(X) - 2 * h2(X)
  return(y)
}
y1 = Y(-2)
y2 = Y(2)
```

Wir erhalten $Y(-2) = -1$ und $Y(2) = 1$. Skizzieren ist nun relativ simpel, da die Funktion von -2 bis 1 linear ist mit Punkten $(-2, -1)$ und $(0, 1)$. Danach haben wir eine negative quadratische Funktion mit Punkt $(2, 1)$ welche im Punkt $(1, 2)$ glatt ist und wir somit nur mit etwas Schwung die Gerade in eine Kurve skizzieren müssen, die dann in $(2, 1)$ endet. Zum Vergleich ein maschineller Plot:



Aufgabe 2

Der erste Term

$$\sum_{i=1}^n (y_i - g(x_i))^2$$

ist der Least Squares Term. Dieser wird minimal, wenn die Kurven die Trainingspunkte interpolieren. Der zweite Term

$$\lambda \int_a^b \left| g^{(3)}(x) \right|^2 dx$$

ist ein der Glättungsterm (Misst die ‘Kurvigkeit der Funktion’) mit Glättungsparameter λ , der als Strafterm den Funktionswert für starke Veränderungen erhöht. Die Ableitung einer Funktion ist ein Maß für die ‘Veränderung’ einer Funktion. Das heißt, je höher die Ableitung, desto stärker misst man Veränderungen. λ ist dann das Gewicht für den Strafterm. Erhöht man den Wert des Strafterms für die Veränderung, so steigt der Trainingsfehler (Die Funktion wird glatter und interpoliert weniger).

\hat{g}_2 lässt kurvigere Funktionen als \hat{g}_1 zu und kann somit besser interpolieren (Kleinerer Trainingsfehler). Für $\lambda \rightarrow \infty$ wird der Strafterm maximiert und nur noch eine maximal glatte Funktion zugelassen, sprich die Zielfunktion strebt gegen eine Gerade. Für $\lambda \rightarrow 0$ wird der Strafterm minimiert, somit ignoriert und folglich strebt die Funktion gegen die Interpolation.

Somit erhalten wir:

- a) \hat{g}_1 hat im Allgemeinen einen kleineren Trainingsfehler, da die Zielfunktion langsamer sich einer Geraden annähert.
- b) \hat{g}_2 hat im Allgemeinen einen kleineren Testfehler, da starke Schwankungen schneller glatt gebügelt werden.
- c) \hat{g}_2 hat im Allgemeinen einen kleineren Trainingsfehler, da stärkere Interpolation.
- d) \hat{g}_1 hat im Allgemeinen einen kleineren Testfehler, da schwächere Interpolation.