
Arbeitsblatt 8

A 1 Arbeiten Sie weiter mit dem Datensatz `mcycle`.

- Schätzen Sie \hat{f} jeweils über eine quadratische und eine kubische Regression Spline mit einem Knoten im Median der Daten: Erstellen Sie dazu jeweils eine geeignete Designmatrix mithilfe der trunkeerten Potenzfunktionen als Basiserweiterung in X und wenden Sie dann die Funktion `lm` an.
- Bestimmen Sie für jedes Modell die optimale Anzahl an Knoten K_{CV} mit Kreuzvalidierung. Dabei sollen die Knotenpunkte jeweils an den entsprechenden Quantilen liegen. Sie können hier die Basisfunktionserweiterung über B-Splines nutzen, die in der Funktion `bs` aufgestellt wird.
- Berechnen Sie die Anzahl an freien Parametern in den vier Modellen (quadratisch/kubisch, 1 Knoten/ K_{CV} Knoten)
- Wir definieren nun k als die Anzahl freier Parameter der kubischen Regression Spline mit K_{CV} Knoten. Schätzen Sie \hat{f} auch als natürliche kubische Regression Spline mit k freien Parametern
- Schätzen Sie \hat{f} auch als Smoothing Spline mit k “effective degrees of freedom“
- Schätzen Sie \hat{f} auch als Smoothing Spline indem Sie den Smoothing Parameter λ über Kreuzvalidierung schätzen. Sind die resultierenden “effective degrees of freedom“ kleiner, größer oder gleich k ?
- Fügen Sie die kubische Regression Spline und die natürliche kubische Regression Spline mit k freien Parametern sowie die Smoothing Spline mit k “effective degrees of freedom“ in das Streudiagramm des letzten Arbeitsblatts.
- Beschreiben Sie Unterschiede und Gemeinsamkeiten der polynomialen, der Spline- und der Smoothing-Spline-Schätzer von f . Für welches Modell würden Sie sich abschließend entscheiden?

A 2 In dieser Aufgabe soll gezeigt werden, dass eine natürliche kubische Spline mit K Knotenpunkten K freie Parameter hat. Da jede kubische Spline über eine Basis der trunkeierten Potenzfunktionen darstellbar ist, schreiben wir f dazu zunächst als

$$f(x) = \sum_{j=0}^3 a_j x^j + \sum_{k=1}^K b_k (x - \xi_k)_+^3$$

Dabei werden die ersten vier Parameter mit a_0, a_1, a_2, a_3 bezeichnet, damit der Index von b in der zweiten Summe bei 1 beginnen kann. Das vereinfacht die Darstellung später und hat sonst keine Bedeutung.

- a) Welche zusätzlichen Eigenschaften hat eine natürliche kubische Spline im Gegensatz zu einer allgemeinen kubischen Spline?
- b) Zeigen Sie, dass diese Eigenschaften den vier Bedingungen an die Parameter

$$a_2 = 0, \quad a_3 = 0, \quad \sum_{k=1}^K b_k = 0, \quad \sum_{k=1}^K b_k \xi_k = 0$$

entspricht.

- c) Begründen Sie damit, dass die Anzahl freier Parameter K ist.
- d) Zeigen Sie mit diesen Ergebnissen weiter, dass jede natürliche kubische Spline über die folgende Basisfunktionserweiterung darstellbar ist

$$f(x) = a_0 + a_1 x + \sum_{k=1}^{K-2} \tilde{b}_k \cdot \left(\frac{(x - \xi_k)_+^3 - (x - \xi_{K-1})_+^3}{\xi_K - \xi_k} - \frac{(x - \xi_{K-1})_+^3 - (x - \xi_K)_+^3}{\xi_K - \xi_{K-1}} \right)$$

(\tilde{b}_k statt b_k , da der Parameter nicht dem Wert b_k aus den vorangegangenen Aufgabenteilen entsprechen muss.)