NLNP Praktikum 9

Robin Baudisch, Merlin Kopfmann, Maximilian Neudert

Inhaltsverzeichnis

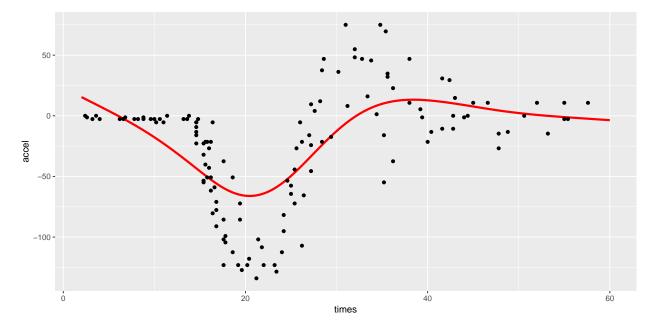
A1																															2
																															2
	f)										 																				2
	g) .	•			•																				•		•			4
A2	2																														6
	a) .																													6
A3	3)																														8
	a) .									 																				8
	b) .									 																				9
	c)) .			 					 	 										 										10
	d) .								 	 																				11
	e) .			 						 										 										14
	f)		•			•																				•		•			14
A4	ļ																														15

A1

e)

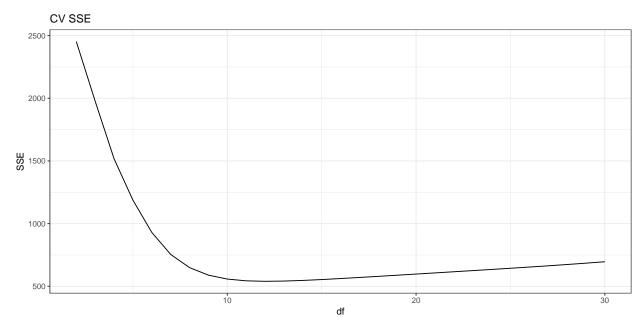
Wir wählen nun k=5 als effective degrees of freedom und berechnen damit \hat{f} als Regression Smoothing Spline.

```
data = mcycle
RSS = smooth.spline(x = data$times, y = data$accel, df = 5)
fx = seq(2, 60, 0.1)
fy = predict(RSS, fx)$y
ggdf = data.frame(x = fx, y = fy)
gg = ggplot(data = ggdf, mapping = aes(x = x, y = y))
gg = gg + geom_line(color = "red", size = 1.2)
gg = gg + geom_point(data = mcycle, mapping = aes(x = times, y = accel), color = "black")
gg = gg + xlab("times") + ylab("accel")
gg
```



f)

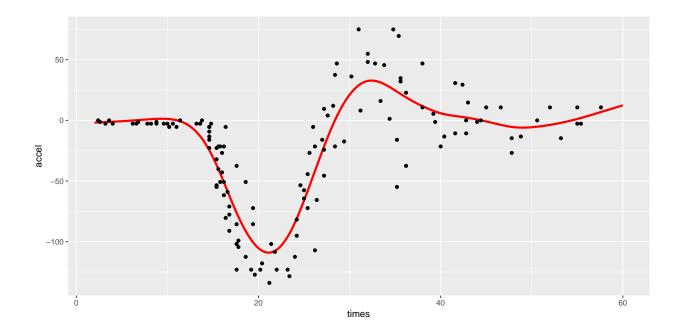
Wir führen im Folgenden eine Parametrisierung für die effective degrees of freedom des smoothing Splines durch. Dabei variieren wir den Wert von 2 bis 30 und untersuchen anschließend anhand einer Grafik, welcher Wert den geringsten Fehler liefert. Den Fehler berechnen wir mit Hilfe einer Leave One Out Cross Validations.



Der optimale Wert für die effektive degrees of freedom ist laut Grafik 10 und damit größer als k. Wir erhalten $\lambda \approx 1.2641699 \times 10^{-6}$.

Wir plotten das Ergebnis.

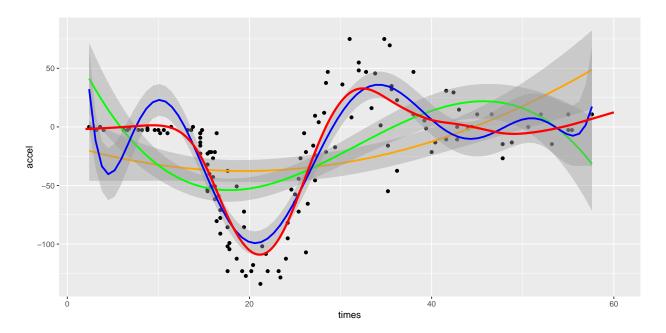
```
data = mcycle
RSS = smooth.spline(x = data$times, y = data$accel, df = 10)
fx = seq(2, 60, 0.1)
fy = predict(RSS, fx)$y
ggdf = data.frame(x = fx, y = fy)
gg = ggplot(data = ggdf, mapping = aes(x = x, y = y))
gg = gg + geom_line(color = "red", size = 1.2)
gg = gg + geom_point(data = mcycle, mapping = aes(x = times, y = accel), color = "black")
gg = gg + xlab("times") + ylab("accel")
gg
```



g)

Jetzt vergleichen wir den RSS mit den polynomialen Regressionen von Grad 2, 3, 8 aus Praktikum 7.

```
poly2 <- lm(data = mcycle, accel ~ poly(times, 2))</pre>
poly3 <- lm(data = mcycle, accel ~ poly(times, 3))</pre>
poly8 <- lm(data = mcycle, accel ~ poly(times, 8))</pre>
RSS = smooth.spline(x = data$times, y = data$accel, df = 10)
fx = seq(2, 60, 0.1)
fy = predict(RSS, fx)$y
ggdf = data.frame(x = fx, y = fy)
gg = ggplot(data = mcycle, mapping = aes(x = times, y = accel))
gg = gg + geom_point()
gg = gg + geom\_smooth(method = "lm", formula = y ~ poly(x, 2),
   color = "orange")
gg = gg + geom\_smooth(method = "lm", formula = y ~ poly(x, 3),
    color = "green")
gg = gg + geom\_smooth(method = "lm", formula = y ~ poly(x, 8),
    color = "blue")
gg = gg + geom_line(data = ggdf, mapping = aes(x = fx, y = fy),
    color = "red", size = 1.2)
gg
```



- Polynomiale Regression von Grad 2: Orange
- Polynomiale Regression von Grad 3: Grün
- Polynomiale Regression von Grad 8: Blau
- RSS mit df = 10: Rot

Das beste Ergebnis nach Sichtprüfung erzielt der Smoothing Spline mit df = 10.

A2

a)

Sei λ fest.

$$\hat{f}(x) = \left(\sum_{i=1}^{n} K_{\lambda}(x, x_i) y_i\right) \left(\sum_{i=1}^{n} K_{\lambda}(x, x_i)\right)^{-1}$$

Der Tricube-Kern ist definiert als

$$K_{\lambda}(x, x_i) = \begin{cases} \left(1 - \left|\frac{x - x_i}{\lambda}\right|^3\right)^3, & |x - x_i| \leq \lambda \\ 0, & \text{sonst.} \end{cases}$$

Für x_i fest ist $K_{\lambda}(x, x_i)$ für jedes x_i ohne $|x - x_i| = \lambda$ als Verknüpfung differenzierbarer Funktionen differenzierbar. Folglich bleiden die Punkte

$$|x - x_i| = \lambda \implies x_0 = \lambda + x_i \text{ und } x_0 = x_i - \lambda$$

als kritische Stellen auf Stetigkeit zu prüfen. Der Kern ist offensichtlich stetig in x_0 , da der Wert beidseitig problemlos gegen 0 konvergiert. Wir prüfen die Differenzierbarkeit:

Sei $x_0 = \lambda + x_i$.

$$\lim_{h \to 0} = \frac{1}{h} \left(\left(1 - \left| \frac{\lambda + x_i - x_i + h}{\lambda} \right|^3 \right)^3 - \left(1 - \left| \frac{\lambda + x_i - x_i}{\lambda} \right|^3 \right) \right) \tag{1}$$

$$= \lim_{h \to 0} \frac{1}{h} \left(\left(1 - \left| 1 + \frac{h}{\lambda} \right|^3 \right)^3 - (1 - 1)^3 \right)$$
 (2)

$$= \lim_{h \to 0} \frac{1}{h} \left(1 - \left(1 + \frac{h}{\lambda} \right)^3 \right)^3 \tag{3}$$

$$= \lim_{h \to 0} \frac{1}{h} \left(1 - \left(1 + 3\frac{h}{\lambda} + 3\frac{h^2}{\lambda^2} + \frac{h^3}{\lambda^3} \right)^3 \right)^3 \tag{4}$$

$$= \lim_{h \to 0} \frac{1}{h} \left(3\frac{h}{\lambda} + 3\frac{h^2}{\lambda^2} + \frac{h^3}{\lambda^3} \right)^3 = 0$$
 (5)

und der linksseitige Beweis (-h) folgt analog.

Sei $x_0 = x_i - \lambda$.

$$\lim_{h \to 0} = \frac{1}{h} \left(\left(1 - \left| \frac{x_i - \lambda - x_i + h}{\lambda} \right|^3 \right)^3 - \left(1 - \left| \frac{-\lambda + x_i - x_i}{\lambda} \right|^3 \right) \right)$$
 (6)

$$= \lim_{h \to 0} \frac{1}{h} \left(\left(1 - \left| \frac{3}{-1 + \frac{h}{\lambda}} \right| \right)^3 - (1 - 1)^3 \right)$$
 (7)

$$= \lim_{h \to 0} \frac{1}{h} \left(1 - \left(1 - \frac{h}{\lambda} \right)^3 \right)^3 \tag{8}$$

$$= \lim_{h \to 0} \frac{1}{h} \left(1 - \left(1 - 3\frac{h}{\lambda} + 3\frac{h^2}{\lambda^2} - \frac{h^3}{\lambda^3} \right)^3 \right)$$
 (9)

$$= \lim_{h \to 0} \frac{1}{h} \left(-3\frac{h}{\lambda} + 3\frac{h^2}{\lambda^2} - \frac{h^3}{\lambda^3} \right)^3 = 0$$
 (10)

und der linksseitige Beweis (-h) folgt analog.

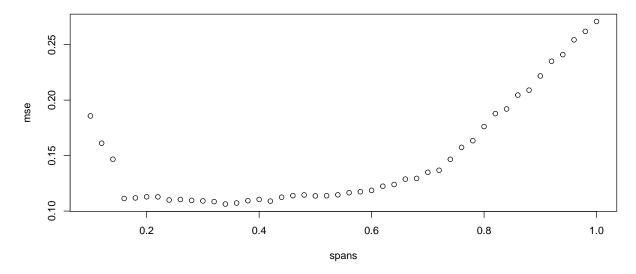
Somit ist $K_{\lambda}(x, x_i)$ stetig differenzierbar und folglich ist $\hat{f}(x)$ ist Verkettung differenzierbarer Funktionen differenzierbar.

A3)

```
set.seed(1337)
```

a)

```
data(ethanol)
loessMod10 <- loess(NOx ~ E, data = ethanol, span = 0.1) # 10% smoothing span</pre>
loessMod30 <- loess(NOx ~ E, data = ethanol, span = 0.3) # 25% smoothing span</pre>
loessMod50 <- loess(NOx ~ E, data = ethanol, span = 0.5)</pre>
spans = seq(0.1, 1, 0.02)
# Randomly shuffle the data
data <- ethanol[sample(nrow(ethanol)), ]</pre>
# Create 10 equally size folds
folds <- cut(seq(1, nrow(data)), breaks = 5, labels = FALSE)</pre>
# Perform 10 fold cross validation
test <- matrix(NA, ncol = 2, nrow = length(spans))</pre>
mse1 <- c()
for (span in spans) {
    mse <- c()
    for (j in 1:5) {
        # Segement your data by fold using the which() function
        testIndexes <- which(folds == j, arr.ind = TRUE)</pre>
        testData <- data[testIndexes, ]</pre>
        trainData <- data[-testIndexes, ]</pre>
        # Use the test and train data partitions however you
        # desire...
        fit <- loess(NOx ~ E, data = trainData, span = span,
             control = loess.control(surface = "direct"))
        y.pred <- predict(fit, newdata = testData$E)</pre>
        y.true = testData$NOx
        mse <- append(mse, mean((y.pred - y.true)^2))</pre>
    mse1 <- append(mse1, mean(mse))</pre>
}
test <- NULL
test$spans <- spans
test$mse <- mse1</pre>
test <- as.data.frame(test)</pre>
plot(test)
```

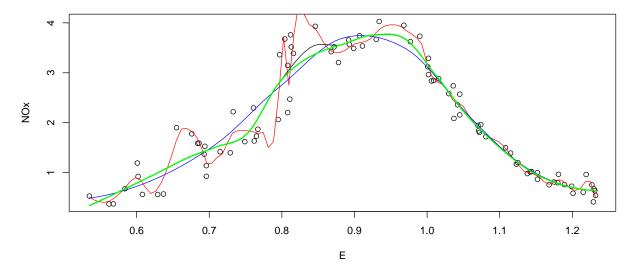


```
opt_spans <- test$spans[test$mse == min(test[, "mse"])]
opt_spans

[1] 0.34
loessMod_opt <- loess(NOx ~ E, data = ethanol, span = opt_spans)</pre>
```

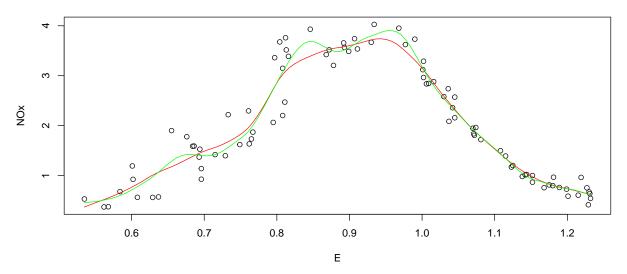
b)

Local Regression: Different Smoothing Params



c)

Linear vs Quadratic Local Regression

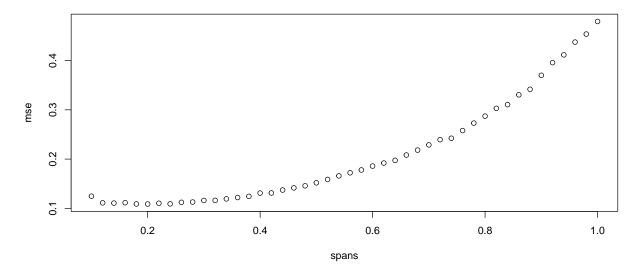


```
lin_pred <- cbind(predict(lin, newdata = c(0.65)), predict(lin,
    newdata = c(0.9)))</pre>
```

	0.65	9
lin	1.146328	3.602708
quad	1.229701	3.562719

d)

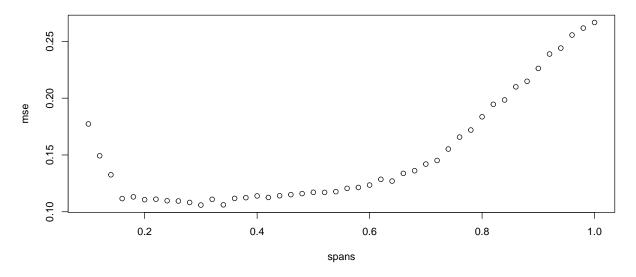
```
mse1 <- c()
for (span in spans) {
    mse <- c()
    for (j in 1:5) {
         # Segement your data by fold using the which() function
        testIndexes <- which(folds == j, arr.ind = TRUE)</pre>
         testData <- data[testIndexes, ]</pre>
         trainData <- data[-testIndexes, ]</pre>
         # Use the test and train data partitions however you
         # desire...
         fit <- locfit(NOx ~ E, data = trainData, alpha = span,
             deg = 1)
         y.pred <- predict(fit, newdata = testData$E)</pre>
         y.true = testData$NOx
        mse <- append(mse, mean((y.pred - y.true)^2))</pre>
    msel <- append(msel, mean(mse))</pre>
}
lin_cv <- NULL</pre>
lin_cv$spans <- spans</pre>
lin_cv$mse <- mse1</pre>
lin_cv <- as.data.frame(lin_cv)</pre>
plot(lin_cv)
```



```
opt_lin <- lin_cv$spans[lin_cv$mse == min(lin_cv[, "mse"])]
opt_lin</pre>
```

[1] 0.2

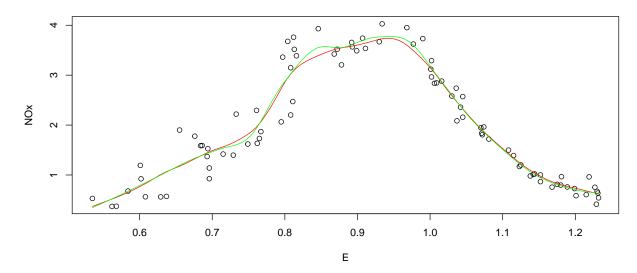
```
mse1 <- c()
for (span in spans) {
    mse <- c()
    for (j in 1:5) {
        # Segement your data by fold using the which() function
        testIndexes <- which(folds == j, arr.ind = TRUE)</pre>
        testData <- data[testIndexes, ]</pre>
        trainData <- data[-testIndexes, ]</pre>
        # Use the test and train data partitions however you
        # desire...
        fit <- locfit(NOx ~ E, data = trainData, alpha = span,
             deg = 2)
        y.pred <- predict(fit, newdata = testData$E)</pre>
        y.true = testData$NOx
        mse <- append(mse, mean((y.pred - y.true)^2))</pre>
    mse1 <- append(mse1, mean(mse))</pre>
quad_cv <- NULL
quad_cv$spans <- spans
quad_cv$mse <- mse1</pre>
quad_cv <- as.data.frame(quad_cv)</pre>
plot(quad_cv)
```



```
opt_quad <- quad_cv$spans[quad_cv$mse == min(quad_cv[, "mse"])]
opt_quad</pre>
```

[1] 0.3

Linear vs Quadratic Local Regression (optimal alphas)



e)

- Größte Varianz: Lokal quadratisch
- · Kleiner Bias: Lokal quadratisch
- Kleinste Varianz: K-Nearest Neighbor
- Größer Bias: K-Nearest Nighbor

und Lokal lineare Regression liegt dazwischen, was in Anbetracht des Bias-Variance-Tradeoff Sinn ergibt, da die Verfahren alle gleich sind mit K-Nearest Grad 0, Lokal Linear Grad 1 und Lokal Quadratisch Grad 2. Das heißt, dass Lokal quadratisch am besten fitten kann, während K-Nearest am meisten glättet.

```
f)
```

[1] 7.093455

```
sum(residuals(loessMod10)^2)
[1] 3.382258
sum(residuals(loessMod30)^2)
[1] 7.18373
sum(residuals(loessMod50)^2)
[1] 9.168455
sum(residuals(loessMod_opt)^2)
[1] 7.369065
sum(residuals(tricube_10)^2)
[1] 3.442665
sum(residuals(tricube_30)^2)
[1] 7.093455
sum(residuals(tricube_50)^2)
[1] 9.067521
sum(residuals(tricube_opt)^2)
[1] 7.358256
sum(residuals(lin_opt)^2)
[1] 7.395092
sum(residuals(quad_opt)^2)
```

A4

Der Gauß Kernel ist definiert als

$$K_{\lambda}(x, x_i) = \frac{1}{\sqrt{2\pi\lambda}} \exp\left(-\frac{(x - x_i)^2}{2\lambda^2}\right)$$
 (11)

Der Kernel gewichtet jeden Datenpunkt zusätzlich zu Least Squares

- λ → ∞: Große Bandbreite (über alle Daten). Der Gauß Kernel konvergiert gegen 0, der Abstand zwischen x_j und den x_i bekommt einen kleinen Skalar und führt deshalb dazu, dass der Wert ŷ_i dem der linearen Regression b̂₀ + b̂₁x_i entspricht.
- λ → 0: Geringe Bandbreite (nur der Punkt selbst). Der Gauß Kernel konvergiert gegen 0, der Abstand zwischen x_j und den x_i bekommt einen großen Skalar und führt deshalb dazu, dass der Wert ŷ_i gegen y_j konvergiert und somit interpoliert.